Clasificación de enfermedades en hojas de caña de azúcar con descriptores de color y textura: ¿reconoce el modelo el síntoma o el contexto de la fotografía?

Mariana Rincón Montoya, Natalia Vallejo Cubides y Mariana Zapata Montoya
Equipo 8 · Big Data y Bioinformática · Universidad EAFIT · Octubre de 2026

Resumen. La identificación visual de enfermedades foliares en caña de azúcar depende de personal entrenado y es difícil de escalar. Evaluamos si descriptores clásicos de color y textura, combinados con aprendizaje supervisado, permiten clasificar 2.311 fotografías (tras retirar 210 duplicados exactos) de un dataset público de Kaggle en cinco categorías: asintomática, colletotricosis, roya (*Puccinia*), mosaico (SCMV) y hoja amarilla (SCYLV). De cada imagen se extrajeron 44 variables (estadísticos RGB, histogramas HSV, entropía y textura de coocurrencia) y se compararon Naive Bayes y máquinas de vectores de soporte (SVM) con una partición por grupos de similitud que evita repartir fotos casi idénticas entre entrenamiento y prueba. El SVM con kernel RBF (C=10), seleccionado por validación cruzada, alcanzó en prueba una exactitud de 80,2 % (IC 95 %: 76,5–83,7 %) y un F1 macro de 0,80, frente a 0,53 de Naive Bayes y 0,07 de la referencia. Un control reveló un sesgo de captura: un árbol que solo ve el ancho y alto de la foto obtiene F1 macro de 0,48. Al segmentar la hoja (ExG, Otsu y morfología) el F1 bajó a 0,74, lo que indica que la hoja contiene la mayor parte de la información, pero que el fondo y las condiciones de captura aportan parte del desempeño. El método es útil como apoyo para priorizar revisión, no como diagnóstico.

Palabras clave: caña de azúcar, enfermedades foliares, visión por computador, textura GLCM, SVM, segmentación, fuga de información.

1. Introducción

La caña de azúcar es uno de los cultivos agroindustriales más importantes de Colombia: En Colombia, el cultivo de caña de azúcar ocupa cerca de 238.000 hectáreas en cinco departamentos, principalmente en el valle del río Cauca. Además, según Asocaña, el 75 % del cultivo pertenece a unas 11.000 familias proveedoras [1].

Sin embargo, este cultivo se ve afectado por enfermedades como la roya, el mosaico y la hoja amarilla, que afectan las hojas y reducen su capacidad para realizar la fotosíntesis, lo que termina disminuyendo el rendimiento. Actualmente, muchas de estas enfermedades se identifican mediante revisiones visuales en campo, un proceso que requiere tiempo y experiencia.

Por eso, la visión por computador puede ser una alternativa más sencilla y económica para apoyar esta identificación. Básicamente, consiste en tomar una fotografía, extraer información de ella y utilizar un modelo que pueda reconocer a qué categoría pertenece. Aunque muchos estudios utilizan redes neuronales profundas [2], estas necesitan grandes cantidades de imágenes y sus resultados pueden ser más difíciles de interpretar. También existe el riesgo de que el modelo aprenda a reconocer el fondo o las condiciones en las que se tomó la fotografía, en lugar de identificar realmente los síntomas de la enfermedad [3]. Esto se conoce como fuga de información [4].

Pregunta. ¿Qué tan bien permiten las características clásicas de color y textura clasificar las fotografías en las cinco categorías del dataset, y en qué medida ese desempeño proviene de la hoja y no del contexto de la foto?.

Objetivos: Evaluar el desempeño de los modelos Naive Bayes y SVM para la clasificación de enfermedades en hojas de caña de azúcar, a partir de características de color y textura, y analizar la influencia del contexto de captura en los resultados.

2. Materiales y métodos

2.1 Datos

Para este trabajo usamos la versión 1 *del dataset Sugarcane Leaf Disease Classification Dataset,* descargado de Kaggle y con licencia MIT [5]. En total, contiene 2.521 fotografías en formato JPEG y a color (RGB), organizadas en cinco carpetas, cada una correspondiente a una categoría. Es importante aclarar que las categorías son las que asignó quien publicó el dataset, pero no se verificó en laboratorio que las hojas tuvieran esos patógenos. Además, las fotos tienen diferentes fondos, como suelo, paja y otras plantas, y sus tamaños también varían, desde 240 hasta 1.600 píxeles por lado.
En nuestro caso, cada fotografía se toma como una unidad de análisis y la categoría a la que pertenece, según la carpeta donde está guardada, es la variable que queremos predecir.

Tabla 1. Composición del dataset antes y después de la depuración, y partición utilizada.

Categoría	Interpretación	Originales	Analizadas	Entren.	Prueba
Asymptomatic	Sin síntomas visibles	522	476	383	93
Colletotrichosis	Colletotrichum / pudrición roja	518	518	415	103
Puccinia	Roya	514	447	357	90
SCMV	Virus del mosaico	462	376	301	75
SCYLV	Virus de la hoja amarilla	505	494	395	99
Total		**2.521**	**2.311**	**1.851**	**460**

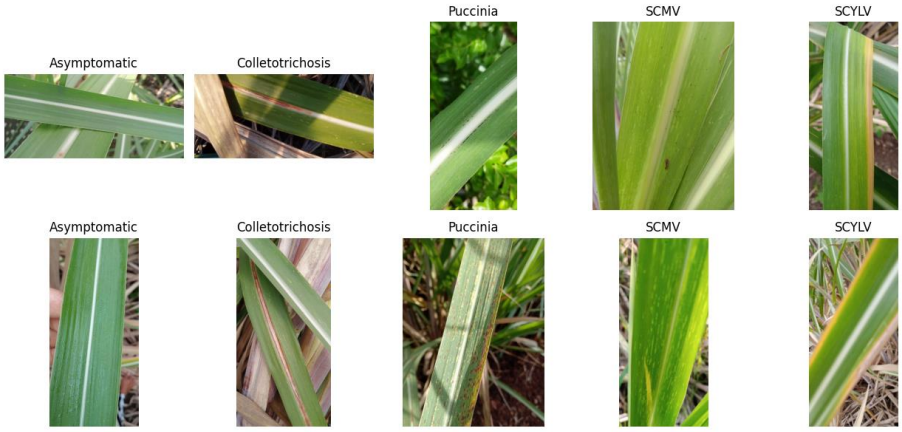


Fig. 1. Dos ejemplos de entrenamiento por categoría. Nótese la variación de fondo (suelo, paja, otras plantas), iluminación y encuadre.

2.2 Depuración y partición sin fuga

Primero revisamos que todas las imágenes abrieran correctamente y encontramos que ninguna estaba dañada. Después, utilizamos un código llamado hash SHA-256, que permite identificar imágenes exactamente iguales. Con esto encontramos y eliminamos 210 imágenes duplicadas.

También usamos otro método llamado pHash, que permite identificar imágenes que se parecen mucho, aunque hayan sido modificadas o comprimidas nuevamente. Con este método encontramos 25 pares de imágenes casi idénticas y las agrupamos para evitar que quedaran separadas. Finalmente, dividimos los datos en dos grupos: 80 % para entrenamiento y 20 % para prueba. Para hacerlo usamos StratifiedGroupKFold con una semilla de 42, que permite mantener una proporción similar de las categorías y asegurar que las imágenes de un mismo grupo queden en un solo conjunto.

La idea de todo esto era evitar que el modelo entrenara y se evaluara con fotografías repetidas o casi iguales, porque eso podría hacer que sus resultados parecieran mejores de lo que realmente son. Por eso, el conjunto de prueba se dejó reservado hasta el final.

2.3 Extracción de características

Para poder comparar las imágenes, primero las ajustamos a un tamaño estándar de 256 píxeles en su lado más largo, sin deformarlas.

Después, de cada imagen extrajimos 44 variables, que son básicamente datos numéricos que describen sus características:

- Color RGB (6 variables): calculamos la media y la desviación estándar de los tres canales (rojo, verde y azul). Esto nos permite conocer los colores predominantes y qué tanto varían.
- Color HSV (32 variables): utilizamos histogramas para describir el tono, la saturación y el brillo de la imagen. En este caso, dividimos el tono en 16 intervalos y la saturación y el brillo en 8 cada uno.
- Entropía (1 variable): mide qué tanta variación de intensidad tiene los píxeles de la imagen en escala de grises.

- Textura GLCM (5 variables): analiza cómo se relacionan los píxeles vecinos para describir la textura de la hoja. Se calcularon contraste, disimilitud, homogeneidad, energía y correlación, teniendo en cuenta cuatro direcciones.

En pocas palabras, convertimos cada fotografía en 44 valores numéricos que resumen su color y textura. Estos son los datos que después utilizan los modelos para aprender a diferenciar las categorías.

Segmentación de la hoja. Para separar la hoja del fondo se calculó el índice de verde excedente ExG = 2g − r − b sobre RGB normalizado [7], Para trabajar únicamente con la hoja, primero hicimos un proceso de segmentación, es decir, separar la hoja del fondo de la fotografía, para esto utilizamos el método de Otsu, que permite separar los píxeles según sus niveles de intensidad. Después aplicamos varias operaciones para mejorar la máscara:

- Apertura (5×5): ayuda a eliminar pequeños elementos que no pertenecen a la hoja.
- Cierre (disco de radio 10 píxeles): permite unir partes de la hoja que quedaron separadas, especialmente por la nervadura central.
- Relleno de huecos: ayuda a completar espacios internos que quedaron sin seleccionar.
- Componente conexa más grande: selecciona el objeto principal, que en este caso esperamos que sea la hoja.

Una vez obtenida la máscara, volvimos a calcular las mismas 44 variables, pero esta vez utilizando solamente los píxeles que pertenecían a la hoja y no todo el fondo de la fotografía. Sin embargo, en 23 imágenes la máscara cubrió menos del 5 % de la fotografía. Como la segmentación no fue adecuada en esos casos, utilizamos la imagen completa para evitar trabajar con una selección demasiado pequeña.

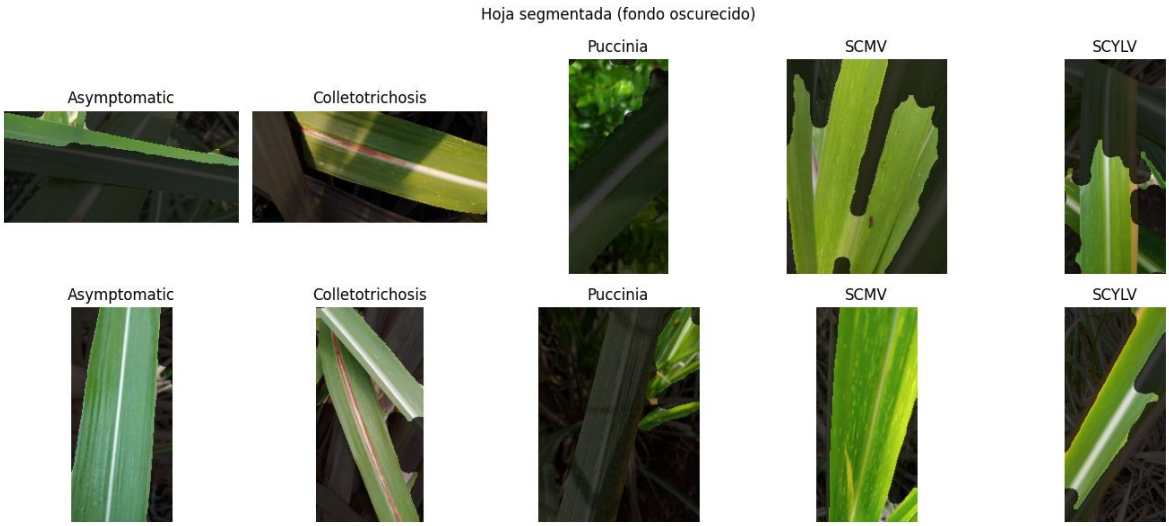


Fig. 2. Resultado de la segmentación (fondo oscurecido). En varios casos la máscara recorta la hoja o incluye hojas vecinas.

2.4 Modelos y evaluación

Comparamos tres modelos: uno de referencia que siempre predice la clase más frecuente, Naive Bayes gaussiano y SVM con kernel RBF, probando valores de C de 1 y 10. Todos incluyeron una estandarización de las variables dentro de un pipeline, para evitar que el modelo aprendiera información de los datos de validación. Para seleccionar el mejor modelo utilizamos el F1 macro mediante una validación cruzada de tres bloques, separando las imágenes por grupos. Después ajustamos los parámetros de SVM probando diferentes valores de C y gamma.

Finalmente, evaluamos el modelo seleccionado con las imágenes de prueba, utilizando exactitud, precisión, sensibilidad y F1. También calculamos intervalos de confianza del 95 % mediante 1.000 remuestreos (bootstrap) para analizar la variabilidad de los resultados.

Para revisar si los resultados del modelo dependen de características de las fotos y no necesariamente de la enfermedad, hicimos tres pruebas. Primero, usamos un árbol de decisión que solo recibe el ancho y el alto de la imagen, sin analizar ningún píxel. Si este modelo logra buenos resultados, significa que el tamaño de las fotos puede

estar relacionado con las clases. Segundo, evaluamos un SVM usando únicamente las características de la hoja segmentada, es decir, tratando de quitar la influencia del fondo. Por último, entrenamos y evaluamos otro SVM usando solo imágenes de 493 × 1040 píxeles, o con esa misma orientación invertida, para comprobar si los resultados se mantienen cuando controlamos el tamaño de las fotografías.

3. Resultados

En la validación cruzada, el SVM con C=10 fue el que obtuvo el mejor resultado, con un F1 macro de 0,804 ± 0,017. Después quedó el SVM con C=1, con 0,762, seguido de Naive Bayes con 0,537 y el modelo de referencia con 0,073. Al probar diferentes combinaciones de parámetros, se confirmó que la mejor configuración era C=10 y γ = scale. Los resultados finales de la evaluación con las imágenes de prueba se muestran en la Tabla 2 y la Figura 3.

Tabla 2. Desempeño en validación cruzada (entrenamiento) y en el conjunto de prueba (n = 460).

Modelo / variables	F1 macro (validación)	Exactitud (prueba)	F1 macro (prueba)
Referencia (clase más frecuente)	0,073	22,4 %	0,073
Solo tamaño de la foto (árbol)	0,499	55,0 %	0,482
Naive Bayes, imagen completa	0,537	53,5 %	0,529
SVM C=1, imagen completa	0,762	79,1 %	0,787
SVM C=10, solo hoja segmentada	0,730	74,6 %	0,740
SVM C=10, imagen completa (seleccionado)	**0,804**	**80,2 %**	**0,798**

El modelo seleccionado acertó 369 de 460 imágenes de prueba (80,2 %; IC 95 %: 76,5–83,7 %; F1 macro 0,80, IC 95 %: 0,76–0,83). Por clase, el F1 fue 0,85 en roya, 0,83 en hoja amarilla, 0,80 en asintomática y colletotricosis, y 0,71 en mosaico. La categoría SCMV fue la más difícil: solo 50 de 75 imágenes se reconocieron, y 10 se clasificaron como asintomáticas (Fig. 4). A su vez, la clase asintomática tuvo alta sensibilidad (0,86) pero menor precisión (0,75): recibe errores de todas las demás categorías.

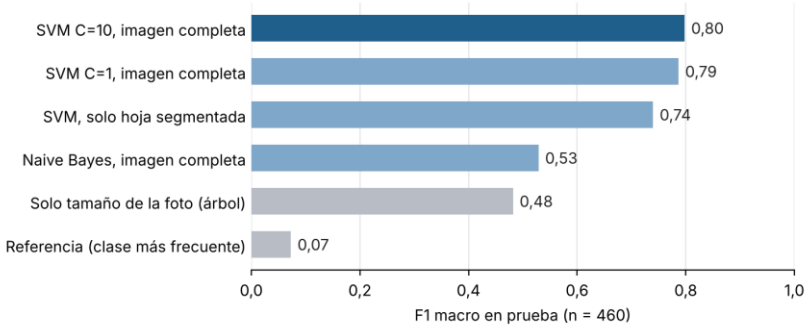


Fig. 3. F1 macro en prueba. En gris, los controles sin información de color o textura; en azul oscuro, el modelo seleccionado por validación.

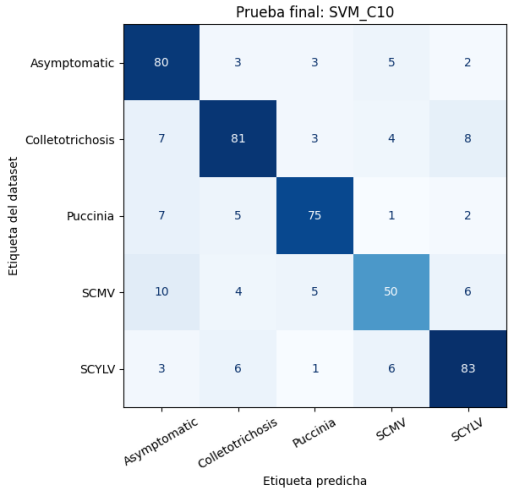


Fig. 4. Matriz de confusión del SVM (C=10) en prueba. Filas: etiqueta del dataset; columnas: predicción.

El árbol de decisión que solo utilizó el tamaño de las fotos obtuvo un F1 macro de 0,48 y una exactitud del 55 %, bastante por encima del modelo de referencia. Esto muestra que el tamaño de las imágenes está relacionado con las clases. Por ejemplo, la mayoría de las fotos de roya tienen un tamaño de 780 × 1040 píxeles, mientras que las de hoja amarilla suelen ser de 493 × 1040.

Por otro lado, al utilizar únicamente las características de la hoja segmentada, el F1 macro fue de 0,74, un poco menor que el obtenido con la imagen completa. Para comprobar si el tamaño de las fotos estaba influyendo en los resultados, también trabajamos con imágenes de una sola resolución. En este caso, usamos 899 imágenes para entrenamiento y 235 para prueba, distribuidas en cuatro clases. El modelo con imágenes completas obtuvo un F1 macro de 0,82, mientras que el de hojas segmentadas alcanzó 0,75. Además, encontramos que la hoja ocupaba entre el 45 % y el 58 % de la imagen, dependiendo de la clase.

4. Discusión

Las variables de color y textura permiten diferenciar las cinco categorías, y esto se refleja en el mejor desempeño del SVM frente a Naive Bayes y al modelo de referencia. Esto puede explicarse porque Naive Bayes asume que las variables son independientes, aunque algunas están fuertemente relacionadas. En cambio, el SVM con kernel RBF puede identificar relaciones más complejas entre ellas.

Los controles de contexto muestran que el tamaño de las fotos también influye en la clasificación. El árbol que solo utilizó el tamaño obtuvo un F1 de 0,48, lo que indica que algunas clases se fotografiaron con cámaras o condiciones diferentes. Sin embargo, esto no explica todo el resultado, porque al trabajar con una sola resolución el modelo alcanzó un F1 de 0,82. Además, al utilizar únicamente la hoja segmentada obtuvo 0,74, lo que muestra que la mayor parte de la información está en la hoja, aunque el fondo también podría aportar pistas. No podemos saber con estos datos si esa diferencia se debe al contexto o a errores en la segmentación.

La confusión más frecuente fue entre mosaico y hojas asintomáticas. Esto puede pasar porque las estrías del mosaico son poco visibles y, al reducir las imágenes, pueden parecerse a una hoja sana. También encontramos casos en los que las sombras y las manchas de sol se confundieron con lesiones. Por otro lado, los resultados pueden variar según cómo se dividan los datos: una ejecución anterior obtuvo 84 % de exactitud, un valor que está dentro del intervalo de confianza reportado.

Limitaciones: Las etiquetas no fueron confirmadas en laboratorio, además, el dataset no incluye información sobre el lugar, la variedad o la planta de origen, por lo que no podemos garantizar la independencia biológica de las imágenes. Finalmente, no probamos el modelo con fotografías de otras regiones, especialmente de cultivos colombianos.

5. Conclusiones

Un método clásico basado en color, textura y SVM, que no requiere GPU y es fácil de interpretar, logró clasificar las cinco categorías con un F1 macro de 0,80. Los controles muestran que la mayor parte de la información está en la hoja, aunque el contexto de captura también influye en los resultados. Esto demuestra que la exactitud por sí sola no cuenta toda la historia.

Para poder utilizarlo como apoyo en campo, por ejemplo para priorizar qué lotes revisar, todavía necesitamos estandarizar la toma de fotografías, mejorar la segmentación, incluir características más específicas de las lesiones y, sobre todo, validar el modelo con imágenes independientes de cultivos colombianos.

Referencias

[1] Blu Radio (2024, 22 de octubre). Asocaña a Petro: cultivos están en 5 departamentos, 238.000 hectáreas, 11.000 familias. https://www.bluradio.com/regiones/pacifico/asocana-a-petro-cultivos-estan-en-5-departamentos-238-000-hectareas-11-000-familias-pr30

[2] Mohanty, S. P., Hughes, D. P. y Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, 7, 1419.

[3] Barbedo, J. G. A. (2018). Factors influencing the use of deep learning for plant disease recognition. *Biosystems Engineering*, 172, 84–91.

[4] Kaufman, S., Rosset, S., Perlich, C. y Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), 15.

[5] Anant1302 (2026). Sugarcane Leaf Disease Classification Dataset (versión 1) [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/anant1302/sugarcane-leaf-disease-classification-dataset

[6] Haralick, R. M., Shanmugam, K. y Dinstein, I. (1973). Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, 3(6), 610–621.

[7] Woebbecke, D. M., Meyer, G. E., Von Bargen, K. y Mortensen, D. A. (1995). Color indices for weed identification under various soil, residue, and lighting conditions. *Transactions of the ASAE*, 38(1), 259–269.

[8] Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1), 62–66.

[9] Cortes, C. y Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20, 273–297.

[10] Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Código, datos derivados y presentación disponibles en el repositorio público del equipo en GitHub (notebook Proyecto-Cana-Equipo8-v2).