UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería

¿Síntoma o contexto?

Clasificación de enfermedades en hojas de caña de azúcar

Mariana Rincón Montoya · Natalia Vallejo Cubides · Mariana Zapata Montoya
Equipo 8 · Big Data y Bioinformática · Universidad EAFIT · 2026

Tres preguntas guían la presentación

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería



QUÉ



CÓMO



PARA QUÉ

La caña es clave y su vigilancia es visual

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería

238.000 ha

de caña en cinco departamentos, sobre todo en el valle del río Cauca (Asocaña, 2024)

11.000

familias son dueñas del 75 % del área sembrada

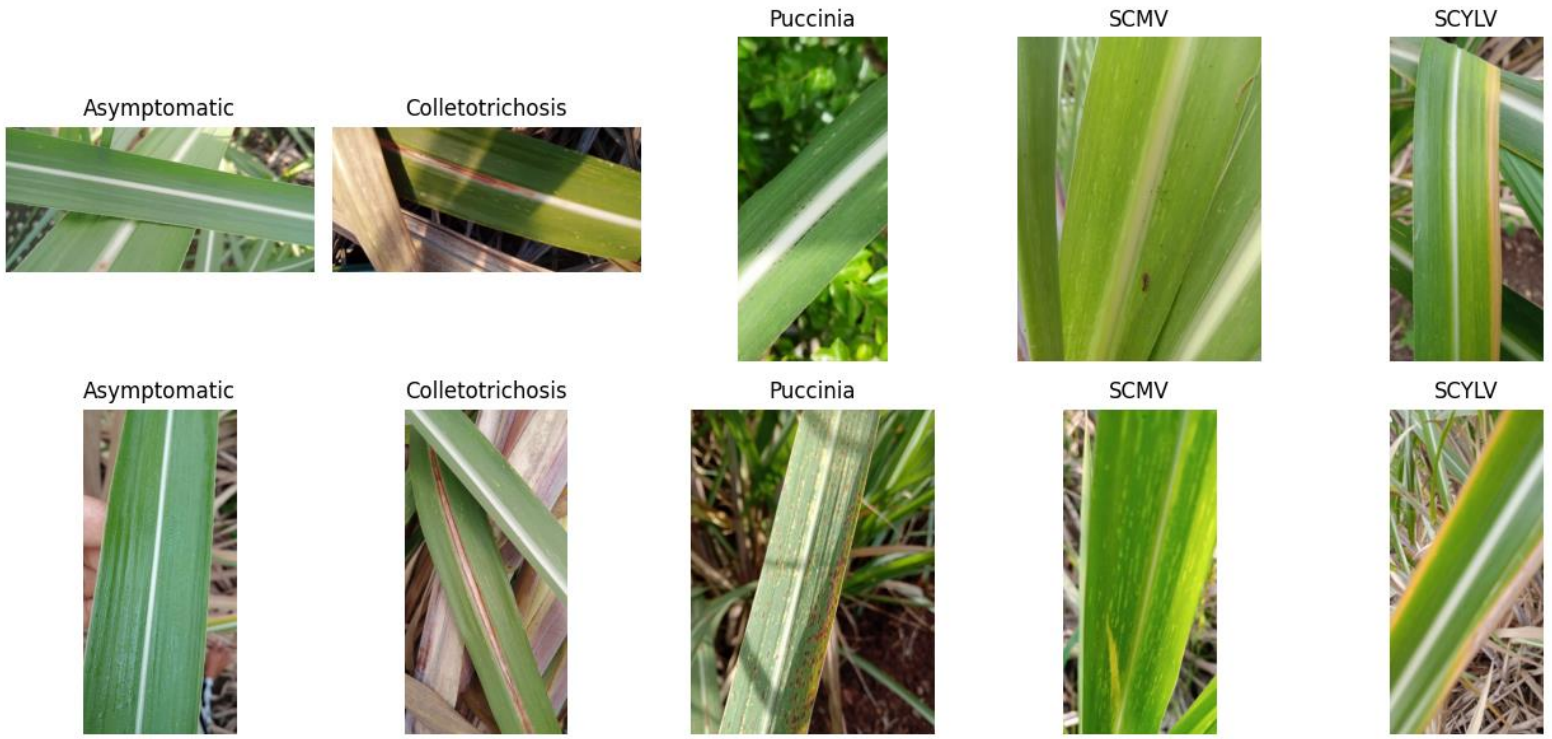
5

categorías: roya, mosaico, hoja amarilla, colletotricosis y asintomática



Detectar enfermedades foliares exige recorrer el cultivo con personal entrenado. Una foto de celular, convertida en números, puede ayudar a decidir dónde mirar primero.

Un dataset público con cinco categorías



2.521 fotos JPEG

Unidad: una fotografía

https://www.google.com/url?q=https%3A%2F%2Fwww.kaggle.com%2Fdatasets%2Fanant1302%2Fsugarcane-leaf-disease-classification-dataset.

LIMPIEZA Y SEPARACIÓN DE LOS DATOS

UNIVERSIDAD EAFIT

Escuela de Ciencias Aplicadas e Ingeniería

2.521 → **−210** → **2.311** → **1.851 / 460**
Entrenamiento/prueba

Categoría	Fotografías
Asymptomatic	522
Colletotrichosis	518
Puccinia	514
SCMV	462
SCYLV	505
Total	2.521

Limpieza:

```
exacto = hashlib.sha256(str(im.size).encode()+im.tobytes()).hexdigest()

n_duplicados = int(df.duplicated('sha_pixels').sum())
df = df.drop_duplicates('sha_pixels').reset_index(drop=True)
```

Separación:

```
divisor = StratifiedGroupKFold(n_splits=5, shuffle=True, random_state=SEED)
idx_train, idx_test = next(divisor.split(df,df.clase,groups=df.grupo))
assert not set(df.iloc[idx_train].grupo) & set(df.iloc[idx_test].grupo)
df['conjunto'] = 'entrenamiento'
df.loc[idx_test,'conjunto'] = 'prueba'
```

CADA FOTO SE CONVIERTE EN 44 NÚMEROS

6 **Color RGB**

```
f = list(rgb.mean(axis=(0,1))) + list(rgb.std(axis=(0,1)))
```

1 **Entropía**

5 **Textura GLCM** Contraste, disimilitud, homogeneidad, energía y correlación

```
f.append(float(-(h*np.log2(h)).sum()))
```

```
f.extend(np.mean(texturas,axis=0))
```

32 **Histogramas HSV** tono en 16 intervalos, la saturación en 8 y el brillo en 8.

```
for canal,n in enumerate([16,8,8]):
    hist,_ = np.histogram(hsv[:,:,canal],bins=n,range=(0,1))
    f.extend(hist/hist.sum())
```

Preparación de X y Y

```
X = np.vstack(filas)
y = df.clase.to_numpy()

print('X:',X.shape,'y:',y.shape)

X: (2311, 44) y: (2311,)
```

so significa que **X tiene 2.311 filas y 44 columnas**. Cada fila corresponde a una fotografía y cada columna a una de las 44 características que extrajeron de esa foto.

Se compararon 3 tipos de modelo

Referencia

Siempre predice la clase más frecuente. Es el resultado más básico

Naive Bayes

Gaussiano, visto en clase. Supone variables independientes.

SVM (RBF)

Fronteras no lineales; C = 1 y C = 10, luego búsqueda de C y γ.

Selección: validación cruzada de 3 bloques por grupos dentro de entrenamiento, con F1 macro (todas las clases pesan igual).

Controles de contexto: un árbol que solo ve el ancho y alto de la foto, y un SVM entrenado solo con fotos de una resolución.

Código	Utilidad
for nombre, modelo in modelos.items()	Repite el proceso para cada modelo.
cross_validate()	Entrena y evalúa automáticamente el modelo tres veces.
X_train	Contiene las 44 características numéricas de las imágenes de entrenamiento.
y_train	Contiene las enfermedades correspondientes a esas imágenes.
cv=cv	Indica cómo repartir los tres bloques de validación.
f1_macro	Evalúa qué tan bien clasifica las cinco enfermedades, dándoles la misma importancia.
accuracy	Calcula el porcentaje total de imágenes clasificadas correctamente.

Evaluacion de los modelos

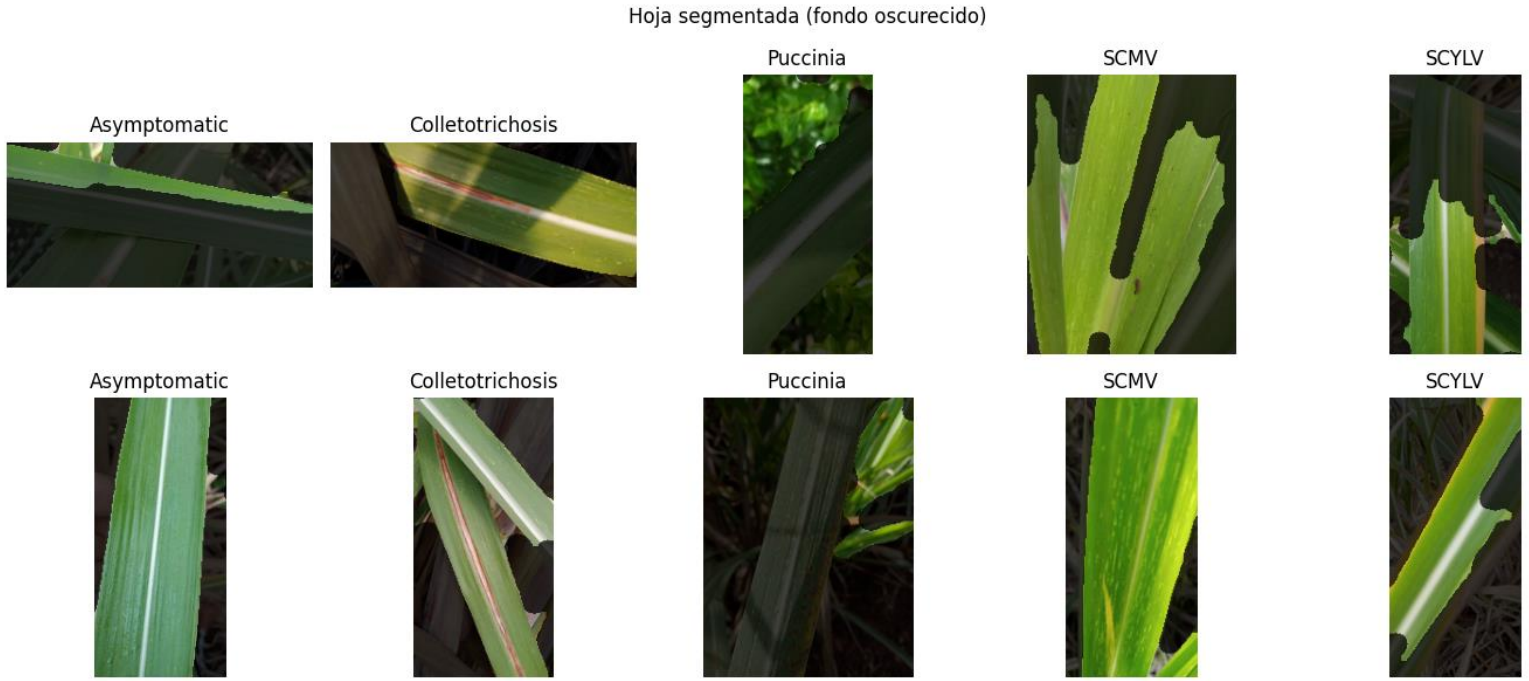
UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería

Modelo	F1 macro promedio	Exactitud en validación	Resultado
Modelo de referencia	0,0733	22,42 %	Desempeño más bajo
Naive Bayes	0,5373	54,40 %	Desempeño intermedio
SVM C=1	0,7618	76,50 %	Buen desempeño
SVM C=10	0,8036	80,55 %	Mejor modelo

Segmentar la hoja para separar síntoma y fondo

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería

1. Índice ExG = 2g − r − b
2. Umbral de Otsu
3. Apertura y cierre con disco
4. Rellenar huecos
5. Componente conexa mayor



Luego se recalculan las mismas 44 variables solo con píxeles de la hoja. Es aproximada: a veces incluye hojas vecinas.

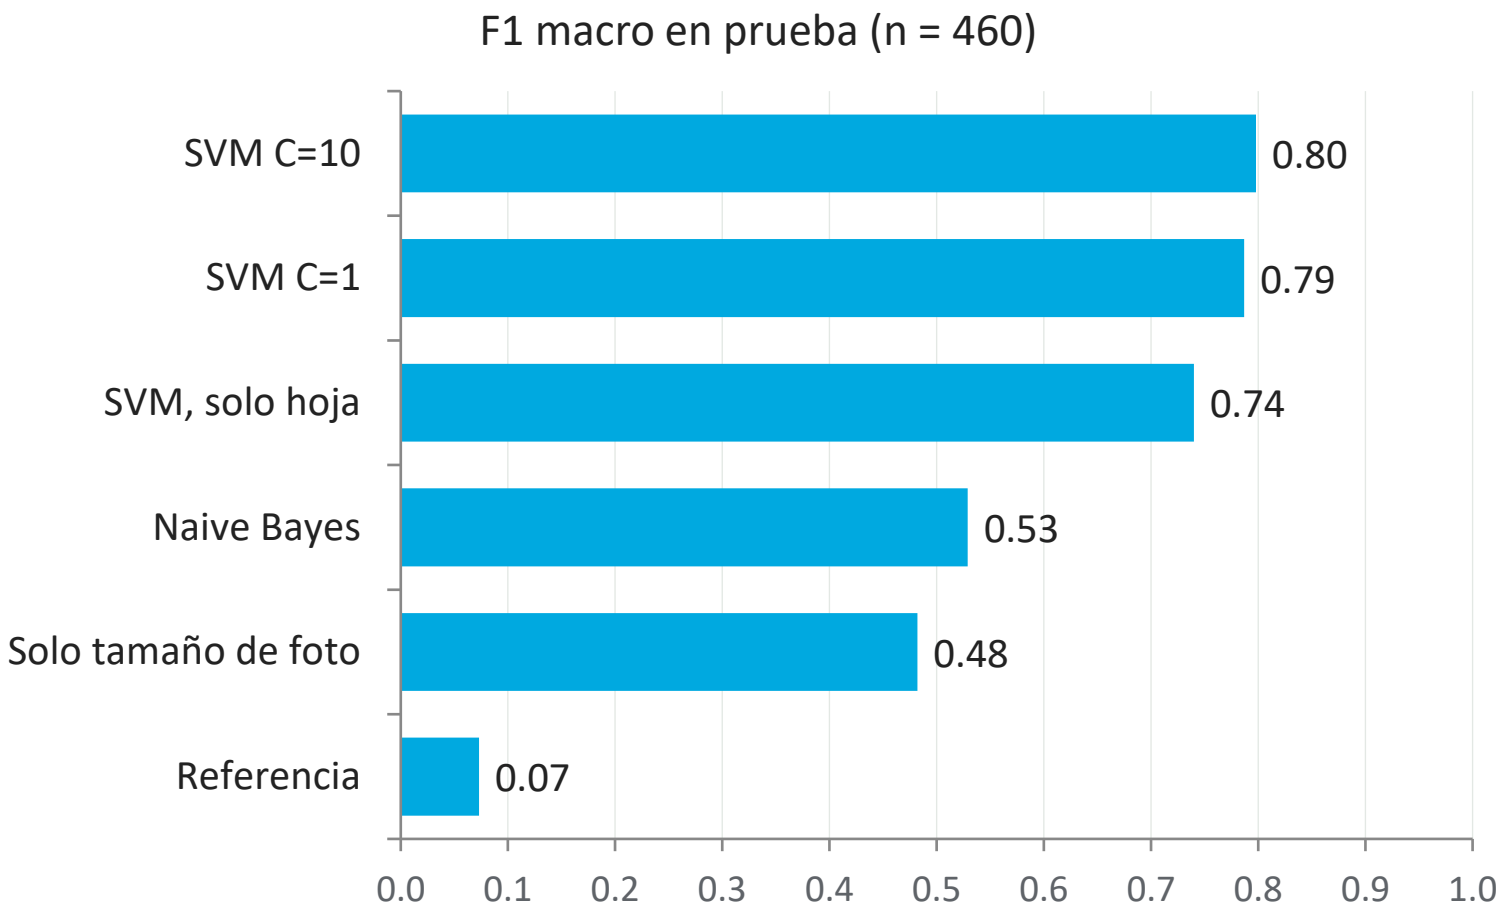
Segmentación

Método	Código	¿Para qué sirvió?
ExG	exg = 2 * g - r - b	Resaltar el color verde de las hojas.
Otsu	m = exg > otsu(exg)	Calcular automáticamente el umbral para separar las regiones.
Apertura	ndi.binary_opening()	Eliminar pequeños ruidos.
Cierre	ndi.binary_closing()	Unir partes separadas de la hoja.
Relleno	ndi.binary_fill_holes()	Recuperar espacios internos, como lesiones.
Región más grande	ndi.label(m) y np.argmax(tamanos)	Conservar el objeto principal, que esperamos que sea la hoja.

RESULTADOS

El SVM acierta 4 de cada 5 fotos nuevas

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería



80,2 %

exactitud del SVM C=10 (369 de 460)
IC 95 %: 76,5–83,7 %

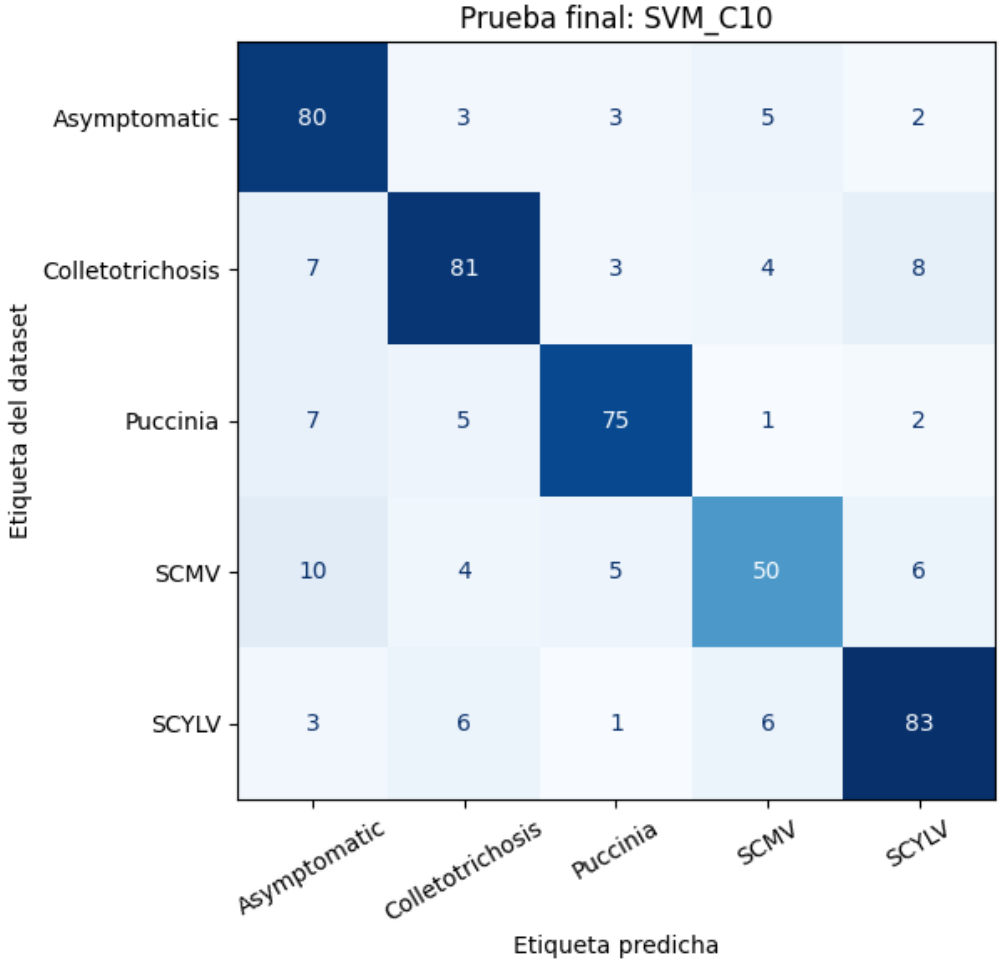
0,80

F1 macro, frente a 0,53 de Naive Bayes

UNIVERSIDAD EAFIT | Escuela de Ciencias Aplicadas e Ingeniería

Matriz de confusión y desempeño por clase

Evaluación final con 460 imágenes de prueba



F1 por clase

Roya (Puccinia)	0,85
Hoja amarilla (SCYLV)	0,83
Asintomática	0,80
Colletotricosis	0,80
Mosaico (SCMV)	0,71

Hallazgo principal
El mosaico (SCMV) fue la categoría más difícil: 50 de 75 imágenes correctas y 10 confundidas con hojas asintomáticas.

Azul oscuro = aciertos en cada categoría.

EL HALLAZGO CLAVE

¿Qué información utiliza realmente el modelo?

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería

0,48

Solo tamaño de la foto

Un árbol de decisión logró clasificar parcialmente las enfermedades usando únicamente el ancho y alto de las imágenes.

0,74

Solo la hoja segmentada

El SVM C=10 obtuvo este F1 macro al utilizar las características de la hoja segmentada.

0,82

Una sola resolución

Al controlar el tamaño de las imágenes, el SVM mantuvo un buen desempeño en cuatro categorías.

Conclusión: La hoja aporta información importante para clasificar, pero las características de las fotografías también pueden influir en los resultados.

¿Por qué se equivoca el modelo?













Iluminación

Las sombras y reflejos pueden parecer manchas o lesiones.

Reducción de tamaño

Al reducir las imágenes a 256 píxeles, algunos síntomas pequeños pueden perder detalle.

Características globales

Los histogramas describen el color general, pero no identifican exactamente dónde está la lesión.

PARA QUÉ

Una herramienta de apoyo, no un diagnóstico

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería

¿Para qué sirve?

- Ayudar a priorizar fotografías o lotes que necesitan revisión.
- Clasificar imágenes sin necesitar una GPU.
- Servir como base para mejorar futuros modelos.

¿Qué no demuestra?

- No confirma qué patógeno está presente.
- No determina la gravedad de la enfermedad.
- No garantiza el mismo desempeño en cultivos colombianos.

El modelo puede apoyar al agrónomo, pero no sustituye una evaluación en campo.

Conclusiones y siguientes pasos

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería

- Logramos clasificar las enfermedades utilizando características de color y textura con SVM, sin necesitar modelos más complejos como las redes neuronales.
- El modelo aprende principalmente de las características de las hojas, pero el fondo, la iluminación y las condiciones de las fotografías también pueden influir en sus resultados.
- Sin embargo, debemos mejorar la segmentación y estandarizar las fotografías para que en el futuro pueda utilizarse de manera más confiable en cultivos reales

Referencias

[1] Blu Radio (2024, 22 de octubre). Asocaña a Petro: cultivos están en 5 departamentos, 238.000 hectáreas, 11.000 familias. https://www.bluradio.com/regiones/pacifico/asocana-a-petro-cultivos-estan-en-5-departamentos-238-000-hectareas-11-000-familias-pr30

[2] Mohanty, S. P., Hughes, D. P. y Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, 7, 1419.

[3] Barbedo, J. G. A. (2018). Factors influencing the use of deep learning for plant disease recognition. *Biosystems Engineering*, 172, 84–91.

[4] Kaufman, S., Rosset, S., Perlich, C. y Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), 15.

[5] Anant1302 (2026). Sugarcane Leaf Disease Classification Dataset (versión 1) [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/anant1302/sugarcane-leaf-disease-classification-dataset

[6] Haralick, R. M., Shanmugam, K. y Dinstein, I. (1973). Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, 3(6), 610–621.

[7] Woebbecke, D. M., Meyer, G. E., Von Bargen, K. y Mortensen, D. A. (1995). Color indices for weed identification under various soil, residue, and lighting conditions. *Transactions of the ASAE*, 38(1), 259–269.

[8] Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1), 62–66.

[9] Cortes, C. y Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20, 273–297.

[10] Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Código, datos derivados y presentación disponibles en el repositorio público del equipo en GitHub (notebook Proyecto-Cana-Equipo8-v2).

UNIVERSIDAD
EAFIT